CENTRO DE EDUCACIÓN TÉCNICA Y SUPERIOR



Minería de datos

Extendiendo el Modelo Multidimensional

Estudiante:

Diego Torres Durante 14021

Prof. Miguel Ricardo González Márquez

Ensenada, BC, a 22 de Septiembre de 2026

Extendiendo el Modelo Multidimensional

1. El espacio vectorial de las imágenes

Una imagen RGB de 256 × 256 píxeles se representa como un tensor de orden 3, I ∈ ℝ^(256 × 256 × 3), donde cada entrada I[i, j, c] es la intensidad (0–255, normalmente escalada a [0, 1]) del píxel en la fila i, columna j y canal c (rojo, verde o azul). Para usarla como una fila de la matriz X se aplana el tensor, por lo que una sola imagen tiene p = 256 × 256 × 3 = 196,608 dimensiones. Al aplanar se pierde la estructura espacial y la distancia entre píxeles no refleja similitud visual; por eso las redes convolucionales (CNN) extraen patrones locales y los comprimen en vectores mucho más pequeños (Goodfellow et al., 2016).

2. El espacio vectorial del texto

El Procesamiento de Lenguaje Natural construye un vocabulario V y asigna a cada palabra o documento un vector numérico. En la codificación one-hot cada palabra es un vector de tamaño |V| con un solo 1, por lo que todas las palabras quedan a la misma distancia (√2): "Feliz" está tan lejos de "Triste" como de "Contento". TF-IDF representa cada documento con un vector disperso de tamaño |V|, ponderando cada término por tf(t, d) × log(N / df(t)), lo que resalta las palabras distintivas y reduce el peso de las comunes. Los word embeddings, como Word2Vec (Mikolov et al., 2013), aprenden vectores densos de 100 a 300 dimensiones a partir del contexto: palabras que aparecen en contextos similares quedan cerca y se capturan relaciones como rey − hombre + mujer ≈ reina.

3. La maldición de la dimensionalidad

James et al. (2023) explican que los métodos basados en distancias, como KNN, se degradan cuando p crece porque cada observación deja de tener vecinos realmente cercanos. Geométricamente, el volumen del espacio crece de forma exponencial y los usuarios de la matriz X quedan cada vez más dispersos: mantener la misma densidad de datos requeriría del orden de 10^p observaciones. Además, las distancias se concentran, ya que (d_max − d_min) / d_min → 0 cuando p → ∞ (Beyer et al., 1999); es decir, el usuario más cercano y el más lejano están prácticamente a la misma distancia y la noción de "usuario similar" pierde sentido. Por ello se aplican técnicas como PCA, selección de variables, regularización o embeddings para reducir la dimensión.

Referencias (APA7)

Beyer, K., Goldstein, J., Ramakrishnan, R., & Shaft, U. (1999). When is "nearest neighbor" meaningful? En C. Beeri & P. Buneman (Eds.), *Database theory — ICDT'99* (pp. 217–235). Springer. https://doi.org/10.1007/3-540-49257-7_15

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. https://www.deeplearningbook.org/

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer. https://doi.org/10.1007/978-3-031-38747-0

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). *Efficient estimation of word representations in vector space* (arXiv:1301.3781). arXiv. https://arxiv.org/abs/1301.3781